

PEDOMAN ARSITEKTUR AI & RAG ENTERPRISE 2024

PT Inovasi Teknologi Cerdas Nusantara

BAB 1: VISI DAN STANDAR PENGEMBANGAN AI

Dokumen ini merupakan standar resmi implementasi kecerdasan buatan bagi seluruh tim engineering.

Tujuan utama adalah membangun sistem Retrieval-Augmented Generation (RAG) yang aman, deterministik, dan bebas halusinasi.

Seluruh model bahasa yang digunakan harus melewati evaluasi kepatuhan privasi data dan memiliki guardrail anti-prompt injection.

BAB 2: STANDAR RETRIEVAL & VECTOR DATABASE

1. Rekomendasi Vector Database:

- Untuk lingkungan local development dan testing: gunakan ChromaDB atau SQLite Vector.
- Untuk lingkungan staging dan production: gunakan Qdrant atau Pinecone Serverless dengan replikasi multi-region.

2. Kebijakan Chunking Teks:

- Ukuran chunk standar (chunk size): 500 sampai 800 karakter.
- Overlap antar chunk: 100 karakter untuk menjaga kesinambungan semantik kalimat.

3. Model Embedding:

- Standar embedding yang disetujui adalah text-embedding-004 (768 dimensi) dengan metrik jarak Cosine Similarity.
- Ambang batas minimum similarity (threshold) untuk context grounding adalah 0.45.

BAB 3: KEAMANAN DATA & PERLINDUNGAN PRIVASI (PII)

1. Dilarang keras mengirimkan data mentah nasabah (PII seperti NIK KTP, nomor kartu kredit, kata sandi, dan rekam medis) ke sistem RAG.

2. Masking Data Otomatis:

- Seluruh data teks harus melewati pipeline Anonymizer sebelum proses chunking dan indexing vektor.
- Log query pengguna disimpan maksimal selama 30 hari dalam format terenkripsi AES-256.

BAB 4: SLA PERFORMA & ANGGARAN BIAYA TOKEN

1. Service Level Agreement (SLA):

- Latency maksimum end-to-end untuk respon RAG adalah 1.5 detik (1500 ms).
- Waktu proses retrieval vektor harus di bawah 150 ms (P95).

2. Kuota dan Anggaran Biaya:

- Anggaran maksimum per project cluster adalah \$500 USD per bulan.
- Wajib menerapkan semantic caching menggunakan Redis untuk kueri berulang guna memangkas biaya token hingga 40%.

BAB 5: TIM PENANGGUNG JAWAB & KONTAK ON-CALL

- Head of AI Engineering: Dr. Budi Santoso (budi.santoso@inovasitech.id)
- Lead Platform & Security: Siti Rahmawati (siti.rahma@inovasitech.id)
- On-call Emergency Slack Channel: #ai-incident-response (SLA respon 15 menit untuk insiden P1).